

近赤外顔画像からの可視スペクトル再構成の性能検証

東 翼^{1,a)} 渡辺 義浩^{1,b)}

概要

近赤外顔画像から可視顔スペクトル画像を再構成する技術は、広範な分野において有用である。本稿では、近赤外光学フィルタ応答関数と可視スペクトル再構成モデルを同時学習する既存手法を改善し、評価する。特に、フィルタ数と再構成モデルの構造を変更し、知覚特性に即した新たな損失関数を導入することで、再構成精度の向上を図る。実験では、従来手法と比べて、再構成精度が定量、定性の両面で向上することを確認した。

1. はじめに

近赤外顔画像から可視顔画像を再構成する技術は、広範な分野において有用である。例えば顔認証では、近赤外顔画像の可視再構成と既存の可視域における認証技術を組み合わせる手法が提案されている [3]。これにより、夜間などの低照度条件下においても、堅牢な顔認証が可能となる。

また、拡張現実では、Dynamic Facial Projection Mapping (DFPM) への応用がある。DFPM は、動的な顔の形状や位置に合わせて投影を行うことで、対象の容貌変容を実現する技術であり、舞台表現やバーチャルメイクアップなどに応用可能である [8]。DFPM では、波長帯により反射率が異なる皮膚に映像を投影するため、所望の色が正確に再現できない色ずれが生じる。顔は色識別感度が高い対象であり、色ずれを補正する色補償が高い精度で求められる。しかし、DFPM では可視光が顔に投影されているため、可視カメラで顔を撮像すると投影光のため、真の顔の外観を取得することができない。そのため、DFPM における顔撮像には、投影光の影響を受けにくい近赤外域のカメラを用いる。したがって、DFPM では近赤外顔画像から可視顔画像を再構成することが色補償のために有用である。

既存の近赤外顔画像から可視顔画像を再構成する技術の多くは、可視顔画像として RGB 顔画像を再構成する [1], [3], [7]。これらの手法は、再構成するのが RGB 画像であるため、高精度な色管理が必要な顔認証や、容貌の評価、DFPM の色補償などで用いるには可視波長方向の情

報が不十分である。また、近赤外域においては、既存の入力画像は 1 チャンネルの単一画像であり、顔の再構成のために最適な波長情報を保持していない可能性がある。

加えて、既存の再構成手法は、畳み込みニューラルネットワークや Transformer といった空間情報を用いるモデルを用いている。これらの手法は、原理的に再構成前後の画像が画素単位で厳密な対応関係を維持できず、顔の輪郭や部位の位置にずれが生じることがある。これは、DFPM における応用では、顔追従や投影画像の色補償を行う位置のずれをもたらす。また、顔認証における応用では、認証の正確性を損なう可能性がある。

これに対し Goh らは、生物物理学的モデルを利用し、近赤外画像を入力として画素単位で顔の可視スペクトルを再構成する手法を提案した [2]。同手法を用いることで、応用上十分な波長解像度で、画素単位で完全に一致する可視顔画像の再構成が可能である。しかし、同手法は、線形モデルを仮定しており、実際の物理現象における複雑な反射成分の影響を含めた正確な再構成が困難である。また、再構成に利用する近赤外波長は、経験的に選択されており、再構成システム全体として最適化されていない。

そこで東らは、ニューラルネットワークを用いて、近赤外光学フィルタの設計と可視顔画像再構成モデルを同時学習する手法を提案した [10]。同手法により、Goh らの手法にて課題であった、モデルの線形性と経験則に依存した近赤外波長選択が解消された。しかし、同手法は、限定的な設定条件でのみ有効性が確認されたものであり、フィルタ数や損失関数において十分に最適化された構成ではない。

そこで本稿では、近赤外顔画像から可視スペクトル顔画像を再構成することを目的とし、東らの手法 [10] を複数の条件において追加的に評価し、再構成精度への影響を分析する。具体的には、東らの手法 [10] より深いネットワーク構造の下で、光学フィルタ数と損失関数を追加する。ここで、光学フィルタ数では、従来 3 枚であったものを 5 枚に増加させる。また、損失関数では、色差 (ΔE) とメラニン指標 (MI)、紅斑指標 (EI) を追加導入し、可視スペクトルの再構成精度を向上させる。実験では、追加検証した構成において、再構成精度が定量、定性の両面で向上していることを確認した。

¹ 東京科学大学

^{a)} higashi.t.9950@m.isct.ac.jp

^{b)} watanabe@ict.eng.isct.ac.jp

2. 関連研究

近赤外域で撮像した顔画像から可視スペクトルの顔画像を再構成する手法として、Goh らは皮膚の生物物理学的モデルを用いた手法を提案した [2]。同手法は、人間の皮膚における主要な色素であるメラニンとヘモグロビンの密度を推定することで、波長変換を実現するものである。同手法は、Lambert-Beer の法則に基づいた可視スペクトル再構成を行う。しかし、実際の皮膚において光は、複雑な光学的相互作用により、厳密には同法則に従わない非線形な過程を辿るため、再構成精度に限界が生じる。また、可視スペクトル再構成のための近赤外入力波長は、経験的に選ばれた固定の 3 波長であり、システム全体の最適化の観点からは検討の余地が残されている。

スペクトル再構成のために経験則に基づいて光学フィルタを選択することは、撮像から再構成に至るシステム全体の最適化の観点から望ましくない。このように、スペクトル再構成が既存の固定的なフィルタ特性に依存することは、一般的な RGB カメラを用いた可視スペクトル再構成でも課題である。これは、既存の RGB カメラのカラーチャンネルは人間の視覚特性に基づき設計されており、スペクトル再構成の観点から最適化されていないためである。そこで Nie らは、カラーチャンネルの光学フィルタ応答関数を学習可能なパラメータとして扱うフレームワークを提案した [6]。同手法では、画像上の位置 (x, y) におけるカラーチャンネル i の画素強度 $I_i(x, y)$ は、分光放射輝度 $L(x, y, \lambda)$ と応答関数 $S_i(\lambda)$ を用いて次のように表されることに着目した。

$$I_i(x, y) = \sum_{n=1}^N S_i(\lambda_n) L(x, y, \lambda_n) \quad (1)$$

この式は、 1×1 畳み込み演算と数学的に等価である。Nie らはこの知見に基づき、再構成ネットワークの直前に光学バンドパスフィルタの物理的制約を付与した 1×1 畳み込み層を配置することで、再構成精度を最大化する光学フィルタ応答関数を自動的に得られることを示した。この応答関数によって得られる観測波長とスペクトル再構成の同時学習の枠組みは、近赤外域を用いた再構成における波長選択の課題に対しても有効なアプローチとなる。

東らは、上記の 2 つの研究に着想を得て、ニューラルネットワークを用いた顔に対する近赤外光学フィルタ構成と可視スペクトル再構成の同時学習手法を提案した [10]。同手法は、近赤外光学フィルタを 1×1 畳み込み層、可視スペクトル再構成モデルをマルチパーセプトロン層として、光学フィルタと再構成モデルの同時最適化を実現する。同手法は、近赤外光学フィルタを 3 枚と設定した場合などの限定的な条件下で有効性が確認されているが、そのほかの設計上の組み合わせでは手法が検証されていない。

3. 近赤外顔画像からの可視スペクトル再構成手法

3.1 モデル構造

3.1.1 光学フィルタ応答関数の最適化

光学フィルタにより入射光のスペクトルが重み付けられ、センサで受光される過程は、式 (1) に示すように 1×1 畳み込み層として学習可能な形で定式化できる。東らの手法では、 1×1 畳み込み層として実装し、損失関数によってフィルタにとって必要となる非負性と平滑性を制約した [10]。これに対し本稿では、物理的な非負性をより確実に担保するため、モデルの順伝播構造そのものに非負性を組み込む。具体的には、 n_f 枚のフィルタによる擬似的なセンサ応答 $\mathbf{f} \in \mathbb{R}^{n_f}$ を次式で示される順伝番として定義する。

$$\mathbf{f} = \tilde{\mathbf{W}} \mathbf{x}_{\text{nir}} \quad (2)$$

ここで、 $\mathbf{x}_{\text{nir}} \in \mathbb{R}^{B_{\text{nir}}}$ は、 B_{nir} を離散化された近赤外スペクトルのバンド数としたときの近赤外スペクトルを離散化したベクトルである。また、 $\tilde{\mathbf{W}} \in \mathbb{R}^{n_f \times B_{\text{nir}}}$ は、各フィルタの近赤外帯域における光学フィルタ応答関数を表現する重み行列である。

$\tilde{\mathbf{W}}$ は、光学フィルタの物理的な非負性を満たすため、学習可能なパラメータ行列 $\mathbf{W}$ に対して要素ごとに Hardtanh 関数を適用し、値域が $[0, 1]$ であるように設定する。

$$\tilde{\mathbf{W}} = \text{Hardtanh}(\mathbf{W}) \in [0, 1]^{n_f \times B_{\text{nir}}} \quad (3)$$

この構造的変更により、損失関数の重み調整に依存することなく、非負性を満たすフィルタの学習が可能となる。

なお、実際の光学フィルタとして作製・運用可能とするためには、平滑制約も必要である。これについては、従来手法と同様に 3.2.1 節で述べる損失関数によって制約する。以上を踏まえて学習された重み $\tilde{\mathbf{W}}$ は、そのまま推論時の光学フィルタ応答関数として用いることが可能である。

3.1.2 ニューラルネットワークによる可視スペクトル再構成

マルチパーセプトロンによって、前節で得られたフィルタ応答 $\mathbf{f}$ から可視スペクトルを各ピクセルで個別に再構成することができる。ここで、皮膚の反射率がメラニンやヘモグロビンといった物理パラメータによって記述できる事実は、可視領域と近赤外領域のスペクトルに強い相関があることを示唆する。この相関関係を背景とすることで、マルチパーセプトロンによるデータ駆動的なスペクトル再構成が可能となる。

本稿では、従来 [10] の 256 ユニットおよび 128 ユニットの 2 層構成よりもモデルの表現力を高めるため、ネットワークのパラメータ数を増加させた。具体的には、入力次元 n_f から始まり、256 ユニットの全結合層を 3 層重ね、

最終層で B_{vis} 次元へ写像する構成とした。なお、 B_{vis} は、離散化された可視スペクトルのバンド数を示す。各中間層の活性化関数には ReLU を用い、出力層には Sigmoid 関数を適用することで、推定スペクトルが正規化反射率として常に $[0, 1]$ の範囲に収まるよう保証している。

3.2 損失関数

3.2.1 光学フィルタ応答関数最適化に対する損失関数

計算により得られる光学フィルタ応答関数を物理的に作成可能な形状にするためには、応答関数に平滑性が必要である。そこで、次の式で与えられる平滑制約 L_{smooth} を損失関数として導入する。

$$L_{\text{smooth}} = \frac{1}{n_f(B_{\text{nir}} - 1)} \sum_{i,l} (\tilde{W}_{i,l+1} - \tilde{W}_{i,l})^2 \quad (4)$$

ここで、 $\tilde{W}_{i,j}$ は、 $\tilde{W}$ の i 行 j 列の要素を表す。

3.2.2 可視スペクトル再構成に対する損失関数

スペクトル形状の忠実度を評価する主項として、従来手法 [10] と同様に平均二乗誤差 (MSE) L_{MSE} を用いる。

$$L_{\text{MSE}} = \frac{1}{B_{\text{vis}}N} \sum_n \sum_{b=1}^{B_{\text{vis}}} (\hat{y}_{(b,n)} - y_{(b,n)})^2 \quad (5)$$

ここで、 N は、データの総数を表し、 $\hat{y}_{(b,n)}$ 、 $y_{(b,n)}$ は、それぞれ n 番目のデータにおける b 番目のバンドでのセンサ応答の再構成値、真値を表す。

従来手法 [10] よりも可視スペクトルの知覚的な再構成精度を向上させるために、色差による損失関数 $L_{\Delta E}$ を補助項として導入する。スペクトルから CIE 1931 等色関数と D65 標準光源を用いて CIE $L^*a^*b^*$ 値を算出する関数を $\text{Lab}(\cdot)$ と表す。このとき、得られた $L^*a^*b^*$ 表色系における CIE76 色差 ΔE の二乗平均を、次式の色差による損失関数 $L_{\Delta E}$ と定義する。

$$L_{\Delta E} = \frac{1}{N} \sum_n \|\text{Lab}(\hat{\mathbf{y}}_n) - \text{Lab}(\mathbf{y}_n)\|_2^2 \quad (6)$$

ここで、 $\hat{\mathbf{y}}_n = [\hat{y}_{(b,1)}, \dots, \hat{y}_{(b,B_{\text{vis}})}]^T$ 、 $\mathbf{y}_n = [y_{(b,1)}, \dots, y_{(b,B_{\text{vis}})}]^T$ である。

色差による損失に加え、肌の物理的な要素に由来するスペクトルの再構成精度も向上させるために、メラニン指標と紅斑指標による損失関数 $L_{\text{MI-EI}}$ を導入する。皮膚科学分野では、特定の可視波長における拡散反射率の比の対数としてメラニン指標および紅斑指標が広く用いられている [9]。本稿では、これらの標準的な定義に従い、スペクトル $\mathbf{y}_n$ に対する両指標を次のように定義する。

$$\text{MI}(\mathbf{y}_n) = \log \frac{y_{(b_{650},n)} + \epsilon}{y_{(b_{480},n)} + \epsilon}, \quad (7)$$

$$\text{EI}(\mathbf{y}_n) = \log \frac{y_{(b_{660},n)} + \epsilon}{y_{(b_{540},n)} + \epsilon} \quad (8)$$

表 1 従来手法との比較。太字は最良の結果を示す。

手法	RMSE ↓	SAM ↓	ΔE ↓
Goh ら	0.0360	5.366	4.953
提案手法 (フィルタ数 3)	0.0246	4.364	3.364
提案手法 (フィルタ数 5)	0.0228	4.024	2.751

表 2 各フィルタ数における提案損失関数の有効性。太字は全体に対する最良の結果、下線は全体に対する次点の結果を示す。

構成	RMSE ↓	SAM ↓	ΔE ↓
全ての損失関数	0.0246	4.364	3.364
フィルタ数 3	$-L_{\Delta E}$	0.0247	4.380
	$-L_{\text{mi-ei}}$	0.0248	4.400
	$-L_{\Delta E} \& -L_{\text{mi-ei}}$	0.0245	4.358
	全ての損失関数	0.0228	4.024
フィルタ数 5	$-L_{\Delta E}$	0.0232	4.091
	$-L_{\text{mi-ei}}$	<u>0.0229</u>	4.021
	$-L_{\Delta E} \& -L_{\text{mi-ei}}$	0.0234	4.082
	全ての損失関数	<u>0.0229</u>	2.738

ここで、 b_λ は波長 $\lambda \text{ nm}$ におけるスペクトルバンドのセンサ応答、 $\epsilon = 10^{-6}$ は対数の発散を防ぐ微小定数である。これらの指標が張る MI-EI 平面上での再構成値と真値のユークリッド距離を損失関数 $L_{\text{MI-EI}}$ として導入する。

$$L_{\text{mi-ei}} = \frac{1}{N} \sum_n \left[(\text{MI}(\hat{\mathbf{y}}_n) - \text{MI}(\mathbf{y}_n))^2 + (\text{EI}(\hat{\mathbf{y}}_n) - \text{EI}(\mathbf{y}_n))^2 \right] \quad (9)$$

スペクトル誤差や色差が全帯域を一樣に評価するのに対し、本項は皮膚色素の診断に用いられる特定波長の反射率比に着目するため、メラニン、ヘモグロビン分布といった生体情報の再現性を直接的に向上させる効果が期待される。

3.2.3 統合された損失関数

以上の議論を踏まえ、今回の学習において使用される損失関数 L は次の式で表される。

$$L = \lambda_{\text{MSE}} L_{\text{MSE}} + \lambda_{\text{smooth}} L_{\text{smooth}} + \lambda_{\Delta E} L_{\Delta E} + \lambda_{\text{mi-ei}} L_{\text{mi-ei}} \quad (10)$$

4. 近赤外から可視スペクトルの再構成実験

4.1 実験条件

実験には、顔のハイパースペクトル画像データセットである HyperSkin を学習と検証のために使用した [5]。同データセットには、400 nm から 1000 nm までを 10 nm 刻みで記録した 51 名分の顔画像が含まれ、400 nm から 700 nm までが可視域、700 nm から 1000 nm までが近赤外域と定義されている。データセットの内 4 名の被験者データは、スペクトルの形状が歪んでいることが確認された。このことから、これらのデータについては実験から除外し、学習用データ 44 名、検証用データ 3 名の計 47 名のデータで実験を行った。学習用と検証用のデータ分割は、顔データの公開制限を踏まえ、筆者が独自に選定した。データセットの画像には、顔のほかに背景も含まれていた。学習と検証は、顔の肌領域のみで実施することが望ましいため、顔




図 1 顔の 3 部位における真値と再構成結果. 左から額, 頬, 唇を表す.




図 2 カラー化したテストデータ. 左から真値, Goh らの手法 [2] による再構成結果, 提案手法 (フィルタ数 5) による再構成結果, 提案手法 (フィルタ数 3) による再構成結果を示す.

の肌領域のみをセグメンテーション [4] によって切り取ることで実験用のデータを生成した.

3.2.3 節の損失関数の重みは, $\lambda_{\text{MSE}} = 10.0$, $\lambda_{\text{smooth}} = 0.01$, $\lambda_{\Delta E} = 0.001$, $\lambda_{\text{mi-ei}} = 0.1$ とした. また, 近赤外光学フィルタ数 n_f は, 従来 [10] と同様の $n_f = 3$ の場合と $n_f = 5$ の場合とで比較検証した. 学習には, $\beta_1 = 0.9$, $\beta_2 = 0.999$ の設定で Adam オプティマイザによる最適化手法を採用した. 学習率は, コサインアニーリングを用いて 100 エポックかけて 1×10^{-3} から 1×10^{-5} へ減衰させた. 3.1.1 節の光学フィルタ層の初期重みは, 0.5 に平均 0, 標準偏差 0.05 のガウスノイズを加算して設定した. 3.1.2 節の再構成層は, Kaiming の一様初期化を適用した.

計算環境として, CPU に Intel Core i9-13900K, GPU に NVIDIA GeForce RTX 5090 を搭載したマシンを使用した. 使用言語は Python であり, ニューラルネットワークの実装には PyTorch 2.11 および CUDA 12.8 を用いた.

比較手法として, Goh らの生物物理学的モデルを用いた手法 [2] との比較を行った. なお, 入力条件を統制するために, 同手法では 3 波長のみの選択とするところを, 700 nm から 1000 nm までの近赤外域すべての波長を用いた.

検証データの評価には, 二乗平均平方根誤差 (RMSE), スペクトル角類似度 (SAM), CIE 1976 色差計算式による色差 (ΔE) を指標として用いた. また, スペクトル画像から等色関数を用いて RGB 画像としてカラー化した画像について定性的な比較を行った.

4.2 結果

表 1 に各手法の定量評価の結果を示す. また表 2 に, 提案手法におけるフィルタ数および損失関数のアブレーション

スタディの結果を示す.

図 1 に, テストデータ内のある 1 名における額, 頬, 唇の 3 部位での真値と再構成結果のセンサ応答を示す. また図 2 に, 各手法によりカラー化したテスト顔画像を示す.

5. 考察

表 1 より, 提案手法は, 定量, 定性ともに Goh らの手法より優れていることがわかる. Goh らの手法と比較して, モデルの表現力が向上したことが要因であると考えられる.

また, 表 2 から, フィルタ数は多い方が再構成精度の向上に有利であることが確認できる. 近赤外スペクトルから可視スペクトルを復元するための情報量が増加したことが要因であると考えられる.

一方, 導入する損失関数の影響は, 評価指標や条件によって異なる挙動を示した. $L_{\Delta E}$ は, フィルタ数 5 の場合, 色差に対して強い効果を示すが, フィルタ数 3 の場合, そのような効果は認められない. $L_{\text{mi-ei}}$ は, フィルタ数 5 の場合, SAM を悪化させるが, フィルタ数 3 の場合, SAM を改善させる. 以上の結果は, 損失関数がすべての条件下で一律に機能するわけではなく, 設定するフィルタ数に応じて各損失関数が果たす役割や相互作用が異なることを示す.

6. 結論

本稿では, 近赤外光学フィルタ応答関数と可視スペクトル再構成モデルを同時に学習する手法の性能検証を行った. 改めて設定したネットワーク構造の下で, 光学フィルタ数と損失関数を追加した構成では, 再構成精度が向上した. 今後は, 計算によって得られた光学フィルタ応答関数を基に光学フィルタを製造し, 実環境での再構成に適用する.

参考文献

- [1] Cai, Y., Lin, J., Lin, Z., Wang, H., Zhang, Y., Pfister, H., Timofte, R. and Van Gool, L.: MST++: Multi-Stage Spectral-Wise Transformer for Efficient Spectral Reconstruction, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pp. 745–755 (2022).
- [2] Goh, K., Matsukawa, T., Okabe, T. and Sato, Y.: Converting near infrared facial images to visible light images using skin pigment model, *Proceedings of the 13th IAPR International Conference on Machine Vision Applications*, pp. 153–156 (2013).
- [3] He, R., Cao, J., Song, L., Sun, Z. and Tan, T.: Adversarial Cross-Spectral Face Completion for NIR-VIS Face Recognition, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 42, No. 5, pp. 1025–1037 (2020).
- [4] Narayan, K., Vs, V. and Patel, V. M.: Segface: Face segmentation of long-tail classes, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39, No. 6, pp. 6182–6190 (2025).
- [5] Ng, P. C., Chi, Z., Verdie, Y., Lu, J. and Plataniotis, K. N.: Hyper-skin: A hyperspectral dataset for reconstructing facial skin-spectra from RGB images, Vol. 36, pp. 24158–24170 (2023).
- [6] Nie, S., Gu, L., Zheng, Y., Lam, A., Ono, N. and Sato, I.: Deeply Learned Filter Response Functions for Hyperspectral Reconstruction, *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4767–4776 (2018).
- [7] Pang, M., Wang, B., Zhou, N., Zhou, Y. and Huang, W.: Reconstructing Prototype From Contaminated Face With Variations Across Heterogeneous Domains, *2024 IEEE International Conference on Multimedia and Expo (ICME)*, pp. 1–6 (2024).
- [8] Peng, H.-L., Sato, K., Nakagawa, S. and Watanabe, Y.: Perceptually-Aligned Dynamic Facial Projection Mapping by High-Speed Face-Tracking Method and Lens-Shift Co-Axial Setup, *IEEE Transactions on Visualization and Computer Graphics*, Vol. 31, No. 10, pp. 6824–6838 (2025).
- [9] Takiwaki, H. et al.: Measurement of skin color: practical application and theoretical considerations, *Journal of Medical Investigation*, Vol. 44, pp. 121–126 (1998).
- [10] 東 翼, 渡辺義浩: 顔画像のためのニューラルネットワークによる近赤外観測波長と可視スペクトル再構成の同時学習の検討, 第 32 回画像センシングシンポジウム (2026).