

MIRU2026 L^AT_EX 2_ε クラスファイルの使い方東 翼^{1,a)} 渡辺 義浩^{1,b)}

概要

本稿は、MIRU2026 用のサンプルです。最初に概要を記述してください。

1. はじめに

近赤外顔画像から可視顔画像を再構成する技術は、広範な分野において有用である。例えば顔認証では、近赤外顔画像の可視再構成と既存の可視域における認証技術を組み合わせる手法が提案されている [4]。これにより、夜間などの低照度条件下においても、堅牢な顔認証が可能となる。

また、拡張現実では、Dynamic Facial Projection Mapping (DFPM) への応用がある。DFPM は、動的な顔の形状や位置に合わせて投影を行うことで、対象の外観を変容させることができる技術であり、舞台表現やバーチャルメイクアップなどに応用可能である [12]。DFPM では、波長帯によって反射率が異なる皮膚に映像を投影するため、所望の色が正確に再現できない色ずれが生じる。顔は色識別感度が高い対象であり、色ずれを補正する色補償が高い精度で求められる。しかし、DFPM では可視光が顔に投影されているため、可視カメラで顔を撮像すると投影光の影響を受け、真の顔の外観を取得することができない。そのため、DFPM における顔撮像には、投影光の影響を受けにくい近赤外域のカメラを用いる。したがって、DFPM では近赤外顔画像から可視顔画像を再構成することが色補償のために有用である。

既存の近赤外顔画像から可視顔画像を再構成する技術は、可視顔画像として RGB 顔画像を再構成する [2], [4], [11]。これは、主に顔認証に用いられるためであるが、DFPM の色補償に用いるには可視波長方向の情報が不十分である。また、近赤外域においても、既存の入力画像は 1 チャンネルの単一画像であり、再構成のためには波長情報が十分ではない可能性がある。加えて、既存の再構成手法は、畳み込みニューラルネットワークや Transformer といった空間情報を用いるモデルを用いている。このため、再構成前後の画像が画素単位で厳密な対応関係を維持できず、顔の輪郭

や部位の位置にずれが生じることがある。これは、DFPM における応用では、顔追従や投影画像の色補償を行う位置のずれをもたらす。また、顔認証における応用では、認証の正確性を損なう可能性がある。

Goh らは、生物物理学的モデルを利用し、近赤外画像を入力として画素単位で顔の可視スペクトルを再構成する手法を提案した [3]。これは、DFPM の色補償に十分な波長解像度で、画素単位で完全に一致する可視顔画像の再構成が可能である。しかし、同手法は、実際の物理現象における複雑な反射成分の影響を含めた正確な再構成が困難である。また、再構成に利用する近赤外波長は、経験的に選択されており、再構成システム全体として最適化されていない。

そこで本稿では、DFPM への応用展開を見据えて、入力画素との明示的な対応関係を維持しつつ、撮像に最適な近赤外波長の選定と可視スペクトル再構成を統合的に学習する手法を提案する。具体的には、複雑で非線形な関係性を近似的に表現できるニューラルネットワークを用いて、各画素を入力に対応画素のみに基づいて明示的な対応関係を保持しつつ、可視スペクトルを再構成する。さらに、近赤外観測波長と可視スペクトル再構成を同時に学習する枠組みを用いて、再構成に有効な近赤外波長の選択を自動化する。実験では、3 つの近赤外バンドパスフィルタを用いて、顔全体の近赤外から可視スペクトルへの再構成が可能であることを示した。

2. 関連研究

2.1 皮膚の生物物理学的モデルを用いた可視スペクトル再構成

近赤外域で撮像した顔画像から可視スペクトルの顔画像を再構成する手法として、Goh らは皮膚の生物物理学的モデルを用いた手法を提案した [3]。同手法は、人間の皮膚における主要な色素であるメラニンとヘモグロビンの密度を推定することで、波長変換を実現するものである。

同手法では、皮膚を表皮と真皮の 2 層からなる散乱媒体と見なす Tsumura らのモデル [10] に基づき、可視スペクトル画像を再構成する。このモデルでは、修正 Lambert-Beer の法則に従い、画像上の各点 (x, y) における放射輝度を各

¹ 東京科学大学^{a)} higashi.t.9950@m.isct.ac.jp^{b)} watanabe.y.cl@m.titech.ac.jp

色素の密度 ρ , 減衰係数 σ , 平均光路長 l の指数関数として定義する. Goh らはこれを多波長観測へ応用し, 対数空間における観測値 $\mathbf{c}$ を推定するモデル $\mathbf{c} = R\mathbf{q} + \mathbf{b}$ (R : スペクトル基底, $\mathbf{q}$: 色素密度, $\mathbf{b}$: バイアス項) を導出した. 同モデルに基づき, 学習段階で顔画像データセットの PCA/ICA により基底 R を同定し, 推論段階では近赤外応答 $\mathbf{c}_{\text{NIR}}$ から最小二乗法により色素マップ $\hat{\mathbf{q}}$ を推定する. 最終的に, この色素マップ $\hat{\mathbf{q}}$ を可視域のモデル式に代入することで, 近赤外情報からの可視スペクトル再構成を実現する.

同手法は, Lambert-Beer の法則に基づいた可視スペクトル再構成を行うが, 実際の皮膚において光は, 複雑な光学的相互作用により, 厳密には同法則に従わない非線形な過程を辿る. 加えて, メラニンやヘモグロビン以外の微量な色素による吸収の影響も無視できないため, 再構成精度に限界が生じる.

また, 可視スペクトル再構成のための近赤外入力波長は, 経験的に選ばれた固定的な 3 波長であり, システム全体の最適化の観点からは検討の余地が残されている. 皮膚の分光反射特性は, 主にメラニンやヘモグロビンなどの皮膚色素によって決定されることを踏まえると, 再構成に寄与する情報の密度は波長ごとに異なると考えられる. 人手による経験的な波長選択では, 皮膚の反射特性と光の反射経路を踏まえた複雑な相互作用を完全には網羅できず, 再構成タスクにおいて有効な情報を見落としている可能性がある.

2.2 RGB 画像からの可視スペクトルの再構成

RGB 画像から可視スペクトル画像を再構成する事例が多く報告されている [1], [2], [9], [14], [17]. RGB 画像は既存の撮像環境で容易に取得可能であり, 可視スペクトル再構成における主要な入力情報となってきた. 先行研究のアプローチは, 空間分布の利用, 生物物理学的モデルの導入, 撮像条件の最適化の三つに大別できる.

第一に, 一般の画像に対して, 畳み込みニューラルネットワーク (CNN) や Transformer を用い, 画像の空間的な分布特性を学習するデータ駆動型の手法が挙げられる. Xiong らは CNN フレームワークによりスペクトル画像の復元精度を向上させた [14]. Cai らは自己注意機構を備えた MST++ により空間・スペクトルの依存関係を効果的に捉える手法を提案した [2]. しかし, これらの空間分布に依存する手法は, 周辺画素の情報を統合する性質上, 物体の境界付近で画素単位の厳密な一致が得られない課題がある [6]. DFPM において投影位置の正確さは没入感に直結するため, 幾何的な対応関係が厳密に得られないことは課題である.

第二に, 顔画像に対して, 画素単位の整合性を保つために生物物理学的モデルを導入する手法がある. Aliaga らは, RGB 拡散反射顔画像からメラニンやヘモグロビン量,

皮膚の厚さといった生物物理学的パラメータを推定し, それに基づき分光反射率を再構成するエンコーダ・デコーダネットワークを提案した [1]. 同手法は, 高精度の反射率再構成が可能であるが, 皮膚の表皮と真皮の物理的なシミュレーションに基づき分光拡散反射率を推定するため, 髭などの皮膚以外の物体の推定が困難である.

第三に, 一般の画像に対して, 撮像時のカラーチャンネルのスペクトル応答関数を最適化するアプローチがある. 従来のカメラのカラーチャンネルは人間の視覚特性に基づいており, スペクトル再構成に最適とは限らない. これに対し Nie らは, カラーチャンネルのスペクトル応答関数を学習可能なパラメータとして扱うフレームワークを提案した [9]. 画像上の位置 (x, y) におけるカラーチャンネル i の画素強度 $I_i(x, y)$ は, 分光放射輝度 $L(x, y, \lambda)$ と応答関数 $S_i(\lambda)$ を用いて次のように表される.

$$I_i(x, y) = \sum_{n=1}^N S_i(\lambda_n) L(x, y, \lambda_n) \quad (1)$$

この式は, 1×1 畳み込み演算と数学的に等価である. Nie らはこの知見に基づき, 再構成ネットワークの直前に光学バンドパスフィルタの物理的制約を付与した 1×1 畳み込み層を配置することで, 再構成精度を最大化するバンドパスフィルタ構成を自動的に得られることを示した. この応答関数によって得られる観測波長とスペクトル再構成の同時学習の枠組みは, 近赤外域を用いた再構成における波長選択の課題に対しても有効なアプローチとなる.

2.3 顔面のスペクトル画像データセット

近赤外画像から可視スペクトルを再構成するモデルを学習するためには, 両波長域が一貫して記録された顔面スペクトルデータセットが不可欠である. Uzair らは, 皮膚の分光特性が生体認証に活用可能かを検証するため, 40 名の被験者の顔面 6 部位 (額, 右頬, 左頬, 唇, 顎, 髪) を対象に, 220 nm から 1100 nm の広帯域を 0.5nm 刻みで測定した UWA-FSRD を構築した [13]. 同データセットは, 波長解像度が高い一方, 反射プローブを用いた点計測に基づいているため顔画像として一貫した再構成がなされているかを確認できない課題がある.

顔全体を画像として保持したデータセットには, Ng らによる HyperSkin がある [8]. 同データセットは 51 名の被験者を対象に, 1024×1024 の高解像度かつ 400 nm から 1000 nm の範囲で 1 nm 単位で撮像されたハイパースペクトル画像群である. 一般に公開されているデータの波長解像度は, 10 nm 単位へと再編集されており UWA-FSRD に劣るが, 一貫性を保った顔の再構成ができていないかを確認するのに十分な空間解像度を持つ. 本稿では, Ng らの HyperSkin を利用し, 実験を行う.

3. 近赤外取得波長最適化と可視スペクトル再構成の同時学習手法

3.1 手法概要

本節では、近赤外域における顔撮像のためのカメラ用バンドパスフィルタの選択から可視スペクトル再構成モデルまでを一貫して学習する手法を導入し、波長選択の自動化および再構成精度の向上を目指す。加えて、可視スペクトル再構成にニューラルネットワークを導入し、皮膚における非線形な光の挙動を近似し、再構成精度を向上させることを目指す。

本手法は、顔撮像のための Q 個の近赤外バンドパスフィルタの選択と近赤外顔画像から可視顔スペクトルを再構成するモデルを同時に学習する。入力として、近赤外域における顔のスペクトル画像を利用し、 1×1 畳み込み層を仮想的なバンドパスフィルタとして適用することで、中間出力として Q 個の近赤外カメラチャンネルにおける観測値を得る。この観測値を可視スペクトル再構成のためのニューラルネットワークの入力とし、最終的な出力である可視域における顔スペクトル画像を得る。

学習過程においては、再構成誤差に加え、物理的に製作可能なバンドパスフィルタ特性を維持するための正則化項を損失関数に導入する。これにより、再構成精度を最大化する最適な近赤外波長の選択と、可視スペクトル再構成モデルの同時最適化を実現する。

3.2 ニューラルネットワークによる可視スペクトル再構成

顔画像上の点 (x, y) における波長 λ での入射光の放射照度 $E(x, y, \lambda)$ と反射光のカメラ方向への分光放射輝度 $L(x, y, \lambda)$ の関係は、皮膚色素等に依存する個人の皮膚光学パラメータ $\mathbf{p}(x, y)$ を媒介として、非線形関数 f により次式で与えられる。

$$L(x, y, \lambda) = f(E(x, y, \lambda), \mathbf{p}(x, y)) \quad (2)$$

式 (2) を N 波長のベクトル表現として次のように拡張する。

$$\mathbf{L}(x, y) = [L(x, y, \lambda_1), \dots, L(x, y, \lambda_N)]^T \quad (3)$$

$$\mathbf{E}(x, y) = [E(x, y, \lambda_1), \dots, E(x, y, \lambda_N)]^T \quad (4)$$

また、 $\mathbf{L}(x, y), \mathbf{E}(x, y)$ を K 個の可視成分 $\mathbf{L}_{\text{VIS}}(x, y), \mathbf{E}_{\text{VIS}}(x, y)$ と $N - K$ 個の近赤外成分 $\mathbf{L}_{\text{NIR}}(x, y), \mathbf{E}_{\text{NIR}}(x, y)$ として以下のように分離して表す。

$$\mathbf{L}_{\text{VIS}}(x, y) = [L(x, y, \lambda_1), \dots, L(x, y, \lambda_K)]^T \quad (5)$$

$$\mathbf{E}_{\text{VIS}}(x, y) = [E(x, y, \lambda_1), \dots, E(x, y, \lambda_K)]^T \quad (6)$$

$$\mathbf{L}_{\text{NIR}}(x, y) = [L(x, y, \lambda_{K+1}), \dots, L(x, y, \lambda_N)]^T \quad (7)$$

$$\mathbf{E}_{\text{NIR}}(x, y) = [E(x, y, \lambda_{K+1}), \dots, E(x, y, \lambda_N)]^T \quad (8)$$

このとき、個人の皮膚光学パラメータ $\mathbf{p}(x, y)$ を関数 g を用いて次のように表現する。

$$\mathbf{p}(x, y) = g(\mathbf{E}_{\text{NIR}}(x, y), \mathbf{L}_{\text{NIR}}(x, y)) \quad (9)$$

式 (9) を式 (2) における可視成分の関係式に代入と以下の式を得る。

$$\mathbf{L}_{\text{VIS}}(x, y) = f(\mathbf{E}(x, y), g(\mathbf{E}_{\text{NIR}}(x, y), \mathbf{L}_{\text{NIR}}(x, y))) \quad (10)$$

前処理により、光源の分光分布や強度の影響を正規化したと仮定することで、式 (10) における $\mathbf{E}(x, y), \mathbf{E}_{\text{NIR}}(x, y)$ を定数と見なすことができる。このとき、可視域の分光放射輝度は近赤外域の分光放射輝度の非線形関数 $\tilde{f}$ を新たに定義することで、次式で表される。

$$\mathbf{L}_{\text{VIS}}(x, y) = \tilde{f}(\mathbf{L}_{\text{NIR}}(x, y)) \quad (11)$$

一方、 Q 個のチャンネルを持つ近赤外カメラの各チャンネル i における応答 c_i は、カメラチャンネル i における近赤外バンドパスフィルタのスペクトル応答関数 $s_i(\lambda)$ を用いた線形積分方程式で表される。これを $N - K$ 点の離散化波長において近似すると、フィルタ応答 $\mathbf{s}_i = [s_i(\lambda_1), \dots, s_i(\lambda_{N-K})]$ と近赤外の分光放射輝度 $\mathbf{L}_{\text{NIR}}$ の内積として次のように記述できる。

$$c_i(x, y) \approx \mathbf{s}_i^T \mathbf{L}_{\text{NIR}}(x, y) \quad (12)$$

ここで、再構成対象である可視スペクトルの次元数 K に対し、近赤外域で選択されるチャンネルの数 Q は極めて少ない。そのため、 Q 個の観測値 $\mathbf{c}(x, y) = [c_1(x, y), \dots, c_Q(x, y)]$ から可視スペクトル $\mathbf{L}_{\text{VIS}}$ を推定することは、数学的に劣決定な逆問題となる。

そこで、本手法ではニューラルネットワークを用いて、顔のスペクトルデータセットに内在する統計的な事前知識をモデルに学習させる。これにより、ニューラルネットワークは非線形な写像 ϕ を通じて、劣決定系における解空間の中から、人間の皮膚として尤もらしいスペクトル形状を推定することが可能となる。

観測値 $\mathbf{c}(x, y)$ から可視スペクトル $\mathbf{L}_{\text{VIS}}$ へのマッピングは、学習されたパラメータ $\mathbf{w}$ を持つネットワークを用いて次のように定式化される。

$$\hat{\mathbf{L}}_{\text{VIS}}(x, y) = \phi(\mathbf{c}(x, y); \mathbf{w}) \quad (13)$$

3.3 近赤外取得波長最適化と可視スペクトル再構成の同時学習

3.2 節に基づくと、近赤外反射光から可視スペクトルを推定する過程は、以下の 2 つの段階が統合されたものとして整理できる。

(1) 物理的観測: $\mathbf{L}_{\text{NIR}}(x, y) \xrightarrow{S} \mathbf{c}(x, y)$



図 1 パイプライン

(2) 再構成: $c(x, y) \xrightarrow{\phi} \hat{L}_{\text{VIS}}(x, y)$
 ここで, $S = [s_1^T, \dots, s_Q^T]$ である.

本手法では, この一連の過程をそれぞれ 1×1 畳み込み層とマルチパーセプトロンとして実装する. この際, カメラフィルタのスペクトル応答関数 S に対応する畳み込みカーネルの重みに対し, 物理的なバンドパスフィルタとして製作可能であるための非負制約および波長方向の平滑制約を損失関数に課す [9]. これにより, 学習を通じて可視スペクトルの再現に最も寄与する近赤外の波長帯域が自動的に選択され, それに対応する高精度な再構成モデルを同時に得ることが可能となる.

損失関数には, スペクトルの真値と再構成値の平均二乗誤差 (Mean Squared Error, MSE) L_{MSE} を用いた. また, 非負制約として, 負の値を取る成分のみを罰する正則化項 L_{nonneg} を導入する. チャンネル i における波長 λ_j でのフィルタ応答 $s_i(\lambda_j)$ に対し, 負の部分を $s_i^-(\lambda_j) = \text{ReLU}(-s_i(\lambda_j))$ と定義し, 非負制約正則化項を以下のように与える.

$$L_{\text{nonneg}} = \sum_{i=1}^Q \sqrt{\sum_{j=1}^{N-K} (s_i^-(\lambda_j))^2} \quad (14)$$

平滑制約として, 次式で与えられるフィルタ応答 $s_i(\lambda_j)$ 全体に対する L2 正則化項 L_{smooth} を用いた.

$$L_{\text{smooth}} = \sum_{i=1}^Q \sqrt{\sum_{j=1}^{N-K} s_i^2(\lambda_j)} \quad (15)$$

最終的な損失関数 L は, 次式で与えられる.

$$L = \sigma_{\text{MSE}} L_{\text{MSE}} + \sigma_{\text{nonneg}} L_{\text{nonneg}} + \sigma_{\text{smooth}} L_{\text{smooth}} \quad (16)$$

ここで, σ_{MSE} , σ_{nonneg} , σ_{smooth} は, 各損失の寄与度を制御するパラメータである.

4. 近赤外から可視スペクトルの再構成実験

4.1 実験条件

実験には, 2.3 節で紹介した, Ng らの HyperSkin を学習



図 2 Caption for PNG

と検証のためのデータセットとして使用した [8]. このデータセットには, 400 nm から 1000 nm までの画像が含まれる. 780 nm を基準として, 400 nm から 770 nm までを可視域, 780 nm から 1000 nm までを近赤外域と定義した.

データセットには, 51 名の被験者のデータが含まれていた. データセットは, 作成者のデータの特性を考慮した選択により, 学習用データとして 47 名分, 検証用データとして 4 名分に分割されていた. 今回の学習と検証では, このままの分類でデータセットを利用した. データセットには, 顔のほかに背景も含まれていた. 学習と検証は, 顔領域のみで実施することが望ましいため, 顔領域のみをセグメンテーション [15], [16] によって切り取ることで実験用のデータを生成した.

提案手法のモデルは, バンドパスフィルタの自動選択のための 1×1 畳み込み層と, 得られた近赤外画像から可視スペクトル画像を再構成する 2 つの全結合層に大きく分けられる. このうち畳み込み層について, 1×1 畳み込み層のカーネル数は, 3.2 節で述べた近赤外カメラのチャンネル数 Q に対応する. 今回は, $Q = 3, 23$ の場合の 2 通りで検証した. $Q = 3$ は, 物理的実現可能性を考慮し, 標準的なベイヤーフィルタのピクセル構造と整合性を持つ構成の検証を目的とした. $Q = 23$ は, サンプリングする近赤外波長数 $N - K$ と一致させたものであり, 全波長情報を利用可能な理想的な条件下での再構成性能を評価することを目的とした.

さらに, データセットに含まれる短波長域のノイズが再構成精度に与える影響を定量的に確認するための比較検証を実施した. データセットには, 400 nm から 440 nm までにノイズが多く含まれる. そこで, $Q = 3$ の条件下

において、可視域の範囲をノイズを含む 400 nm から 770 nm の 39 波長の場合とノイズの影響が少ない 440 nm から 770 nm までの 35 波長の場合とで精度比較を行った。なお、 $Q = 23$ の条件では、ノイズの影響が少ない 440 nm から 770 nm までの 35 波長のみで検証を行った。つまり、3.2 節で述べた離散化のためにサンプリングする全波長数 N は 62 または 58、可視域の波長数 K は 39 または 35、近赤外域の波長数 $N - K$ は 23 となる。

ニューラルネットワーク層には、2 層の ReLU 活性化層を挟んだ全結合多層パーセプトロンを用いた。入力層に続き、128 ユニット、256 ユニットの 2 つの隠れ層と ReLU 活性化関数を挟んだ。これは、データセットのデータが $[0, 1]$ に正規化されているためである。

学習には、学習率を 0.001、 $\beta_1 = 0.5$ 、 $\beta_2 = 0.999$ の設定で Adam オプティマイザによる最適化手法を採用した [5]。学習ではミニバッチ学習は行い、バッチサイズは 256 であった。エポック数は最大 200 とした。なお、検証誤差が 30 エポック連続で改善しない場合に学習を終了する Early Stopping を導入した。ネットワークの重みは、平均 0、標準偏差 0.02 の正規分布に従って初期化した。ただし、最終層は平均 0.5、標準偏差 0.02 の正規分布に従って初期化した。式 (16) で表される損失の重みは、 $\sigma_{\text{MSE}} = 1$ 、 $\sigma_{\text{nonneg}} = 0.02$ 、 $\sigma_{\text{smooth}} = 1$ とした。

計算環境として、CPU に Intel Core i9-13900K、GPU に NVIDIA GeForce RTX 4090 を搭載したマシンを使用した。使用言語は Python であり、ニューラルネットワークの実装には PyTorch 2.9.1 および CUDA 13.1 を用いた。

検証データの評価には、平均絶対誤差 (MAE)、平均相対絶対誤差 (MRAE)、スペクトル角類似度 (SAM) を指標として用いた。また、カラー化した際の色差についても評価した。スペクトル画像から RGB 画像を算出するために、等色関数を用いた手法を利用した [7]。

4.2 結果

5. 考察

顔における近赤外観測波長の選択を含めたシステムの全体的な最適化を行う本手法を利用することで、3 つの近赤外バンドパスフィルタを使って顔全体の近赤外から可視スペクトルへの再構成が可能であることが示唆された。再構成に利用可能な情報が限られる 3 チャンネルの場合であっても、近赤外域のすべての情報が利用可能な 23 チャンネルの場合と同等かより優れた再構成結果を示した。このことから、近赤外域のフィルタ構成として、ベイヤーパターンなどの一般的なカラーカメラのフィルタ構成を用いることで、DFPM において本手法による可視スペクトル再構成が応用可能であることが示された。

また、データにノイズがある場合でも、ノイズがない場

合に大きくは劣らない再構成が可能であった。これは、ノイズが比較的多い中でも、データセットに一定程度スペクトルの傾向があったためであると考えられる。

一方、カラー化した場合にはいずれの再構成においても真値と大きな違いが認められた。筆者による定性的な評価では、全体的に白みがかっており、特に、唇を含めた赤みがある領域において、赤さがなくなっていた。これは、スペクトルから XYZ 色空間に変換する等色関数で、主に 600 nm 以下の波長の重みが大い一方、再構成結果ではその領域の再構成精度が低かったことが原因として考えられる。

既存の色空間に適合させるためには、損失関数に等色関数などの色空間にとって重要である波長の精度を高めるための重みづけをすることが考えられる。また、今回の実験では、可視域と近赤外域の境界を 780 nm としたが、これを 700 nm に変更し人間の知覚感度が低い波長帯を再構成に利用することも考えられる。

6. 結論

本稿では、より効率的で高精度な可視スペクトル再構成を実現するために、フィルタ構成と可視スペクトル再構成をエンドツーエンドで学習する手法を提案した。システム全体の最適化の観点を踏まえると、従来手法のような人手による経験的な波長選択ではなく、再構成に利用する近赤外波長を選択する手法が必要となる。本手法を利用することで、3 つの近赤外バンドパスフィルタを使って顔全体の近赤外から可視スペクトルへの再構成が可能であることが示唆された。

提案手法で再構成した結果をカラー化した際に、真値との間に顕著な差異が認められた。この低い色の再現性は、スペクトルから XYZ 色空間へ変換する際に用いる等色関数において重要な 600 nm 以下の波長の再構成精度が低かったことに起因すると考えられる。損失関数において色空間で重要な波長に重み付けを行うことや、近赤外観測波長の帯域を拡大することによって色の再現性が向上することが期待される。

参考文献

- [1] Aliaga, C., Xia, M., Xie, X., Jarabo, A., Braun, G. and Hery, C.: A Hyperspectral Space of Skin Tones for Inverse Rendering of Biophysical Skin Properties, *Computer Graphics Forum*, Vol. 42, No. 4, p. e14887 (2023).
- [2] Cai, Y., Lin, J., Lin, Z., Wang, H., Zhang, Y., Pfister, H., Timofte, R. and Van Gool, L.: MST++: Multi-Stage Spectral-Wise Transformer for Efficient Spectral Reconstruction, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pp. 745–755 (2022).
- [3] Goh, K., Matsukawa, T., Okabe, T. and Sato, Y.: Converting near infrared facial images to visible light images using skin pigment model, *Proceedings of the 13th IAPR International Conference on Machine Vision Applica-*

表 1 精度評価 (AP_{75})

	カテゴリ数 2			カテゴリ数 3			平均
	データセット 1	データセット 2	データセット 3	データセット 4	データセット 5	データセット 6	
ベースライン	88.0	100	100	92.5	63.7	67.3	85.2
軽量化 1	85.0	99.0	96.0	84.7	66.5	13.7	74.1
軽量化 2	83.4	99.8	100	89.8	51.8	47.5	78.7
カーネルレス 1	86.2	98.5	94.0	83.4	69.4	12.5	74.0
カーネルレス 2	85.5	100	100	88.7	51.6	47.9	74.0

表 2 処理時間 (ms)

	Backbone+FPN	Kernel Branch	Feature Branch	Dynamic segmentation	合計
ベースライン	6.258	6.550	2.800	1.814	17.423
軽量化 1	3.002	1.937	1.413	1.608	7.962
軽量化 2	1.474	1.980	0.492	1.756	5.703
カーネルレス 1	2.946	/	1.416	1.741	6.104
カーネルレス 2	1.545	/	0.466	1.704	3.716



図 3 カーネルレス 2 モデルの定性的結果 (左からデータセット 1-6)

- tions, pp. 153–156 (2013).
- [4] He, R., Cao, J., Song, L., Sun, Z. and Tan, T.: Adversarial Cross-Spectral Face Completion for NIR-VIS Face Recognition, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 42, No. 5, pp. 1025–1037 (2020).
- [5] Kingma, D. P.: Adam: A method for stochastic optimization, *arXiv preprint arXiv:1412.6980* (2014).
- [6] Lin, Y.-T. and Finlayson, G. D.: A rehabilitation of pixel-based spectral reconstruction from RGB images, *Sensors*, Vol. 23, No. 8, p. 4155 (2023).
- [7] Magnusson, M., Sigurdsson, J., Armansson, S. E., Ulfarsson, M. O., Deborah, H. and Sveinsson, J. R.: Creating RGB images from hyperspectral images using a color matching function, *IGARSS 2020-2020 IEEE International Geoscience and Remote Sensing Symposium*, IEEE, pp. 2045–2048 (2020).
- [8] Ng, P. C., Chi, Z., Verdie, Y., Lu, J. and Plataniotis, K. N.: Hyper-skin: A hyperspectral dataset for reconstructing facial skin-spectra from RGB images, Vol. 36, pp. 24158–24170 (2023).
- [9] Nie, S., Gu, L., Zheng, Y., Lam, A., Ono, N. and Sato, I.: Deeply Learned Filter Response Functions for Hyperspectral Reconstruction, *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4767–4776 (2018).
- [10] Norimichi, T., Nobutoshi, O., Kayoko, S., Mitsuhiko, S., Hideto, S., Hirohide, N., Syuuichi, A., Kimihiko, H. and Yoichi, M.: Image-based skin color and texture analysis/synthesis by extracting hemoglobin and melanin information in the skin, *ACM Transactions on Graphics*, Vol. 22, No. 3, pp. 770–779 (2003).
- [11] Pang, M., Wang, B., Zhou, N., Zhou, Y. and Huang, W.: Reconstructing Prototype From Contaminated Face With Variations Across Heterogeneous Domains, *2024 IEEE International Conference on Multimedia and Expo (ICME)*, pp. 1–6 (2024).
- [12] Peng, H.-L., Sato, K., Nakagawa, S. and Watanabe, Y.: Perceptually-Aligned Dynamic Facial Projection Mapping by High-Speed Face-Tracking Method and Lens-Shift Co-Axial Setup, *IEEE Transactions on Visual-ization and Computer Graphics*, Vol. 31, No. 10, pp. 6824–6838 (2025).
- [13] Uzair, M., Mahmood, A., Shafait, F., Nansen, C. and Mian, A.: Is spectral reflectance of the face a reliable biometric?, *Optics express*, Vol. 23, No. 12, pp. 15160–15173 (2015).
- [14] Xiong, Z., Shi, Z., Li, H., Wang, L., Liu, D. and Wu, F.: HSCNN: CNN-Based Hyperspectral Image Recovery from Spectrally Undersampled Projections, *2017 IEEE International Conference on Computer Vision Workshops (ICCVW)*, pp. 518–525 (2017).
- [15] Yakhyokhuja, V.: face-parsing, <https://github.com/yakhyo/face-parsing> (2024).
- [16] Yu, C., Wang, J., Peng, C., Gao, C., Yu, G. and Sang, N.: Bisenet: Bilateral segmentation network for real-time semantic segmentation, *Proceedings of the European conference on computer vision (ECCV)*, pp. 325–341 (2018).
- [17] Zhang, J., Su, R., Fu, Q., Ren, W., Heide, F. and Nie, Y.: A survey on computational spectral reconstruction methods from RGB to hyperspectral imaging, *Scientific Reports*, Vol. 12, No. 1, pp. 2045–2322 (2022).